



Žilinská univerzita v Žiline, Elektrotechnická fakulta, KME



Žilinská univerzita v Žiline
Elektrotechnická fakulta
Katedra mechatroniky a elektroniky

PRECIZOVANIE 3D MODELOVANIA OBJEKTOV Z RGB-D SNÍMAČOV

2019

Ing. Jozef Volák

ŽILINSKÁ UNIVERZITA V ŽILINE
ELEKTROTECHNICKÁ FAKULTA
KATEDRA MECHATRONIKY A ELEKTRONIKY

PRECIZOVANIE 3D MODELOVANIA OBJEKTOV Z RGB-D SNÍMAČOV

Študijný program: Telekomunikácie
Študijný odbor: 5.2.15 Telekomunikácie
Školiace pracovisko: Elektrotechnická fakulta, Katedra mechatroniky a elektrotechniky
Školiteľ: doc. Ing. Dušan Koniar, PhD.

2019

Ing. Jozef Volák

Abstrakt

Cieľom tejto práce je výskum možnosti precizovania 3D modelovania objektov z RGB-D senzorov, ktorých aplikácia je zameraná na medicínske účely. Snímanie môže byť vykonávané jedno-kamerovým alebo viac-kamerovým systémom. V práci sú porovnávané systémy zložené z kamier, ktoré pracujú s technológiou štruktúrovaného svetla alebo s meraním doby letu. V práci je opísaný princíp registrácie a rekonštrukcie 3D dát, taktiež je spomenutá možnosť kalibrácie a automatického detegovania kľúčových bodov tváre. Výsledkom práce je analýza jednotlivých systémov a návrh ďalšieho pracovného postupu pri precizovaní modelovania objektov.

ANOTAČNÝ ZÁZNAM – DIZERTAČNÁ SKÚŠKA

Meno a priezvisko: Jozef Volák

Akademický rok: 2018/2019

Názov práce: Precizovanie 3D modelovania objektov z RGB-D snímačov

Počet strán: 39

Počet obrázkov: 30

Počet tabuliek: 2

Počet grafov: 2

Počet príloh: 0

Počet použ. lit.: 31

Anotácia v slovenskom jazyku:

Táto práca sa zaoberá 3D modelovaním objektov pomocou RGB-D snímačov. Hlavnou úlohou práce je opísať problematiku 3D rekonštrukcie dát a možnosti získavania dát z hĺbkových kamier. V práci je taktiež porovnaný a navrhnutý spôsob modelovania jedno-kamerovým a viac-kamerovým systémom.

Anotácia v anglickom jazyku:

This paper deals with the 3D modelling of objects with RGB-D sensors. The main topic of this paper is to describe issues of 3D data reconstruction and the possibility of catching data from depth sensors. This paper also includes comparison between single-sensor modeling and multi-sensor modeling systems.

Kľúčové slová:

RGB-D kamery, 3D rekonštrukcia, registrácia mračien bodov, vyhľadávanie bodov

Školiteľ doktorandskej dizertačnej práce: doc. Ing. Dušan Koniar, PhD.

Konzultant:

Recenzent: _____

Dátum odovzdania práce: 21.1.2019

Obsah

1	Úvod	1
2	Medicínske pozadie výskumu	2
3	Technické pozadie výskumu	4
3.1	Disparitná a hĺbková mapa	4
3.2	PRINCÍP ČINNOSTI RGB-D KAMIER	5
3.2.1	Stereovízia	5
3.2.2	SLS snímače	6
3.2.3	TOF snímače	7
3.3	Mračno bodov a 3D povrch	11
3.4	Spájanie a registrácia mračien bodov	15
3.4.1	Problematika registrácie mračien bodov	15
3.4.2	Spôsoby registrácie mračien bodov	16
4	MOŽNOSTI SKENOVANIA PACIENTOV	20
4.1	Intel RealSense SR300	20
4.2	Microsoft Kinect v2	21
4.3	Kalibrácia kamier	22
4.4	JEDNOKAMEROVÝ SYSTÉM	29
4.5	VIACKAMEROVÝ SYSTÉM	33
4.5.1	Softvérové a hardvérové požiadavky	33
4.5.2	VZÁJOMNÁ KALIBRÁCIA KAMIER	34
4.5.3	Interferencia	36
4.5.4	Detekcia kľúčových bodov	37
5	Návrh téz dizertačnej práce	38
	Záver	39
	Bibliografia	40
	Zoznam publikácií autora	43

Zoznam obrázkov

Obr. 3-1 Princíp stereovízie	5
Obr. 3-2 Princíp SLS kamery.....	6
Obr. 3-3 Princíp činnosti TOF senzorov	8
Obr. 3-4 Sekvenčná impulzná modulácia TOF senzora	9
Obr. 3-5 Kontinuálna impulzná modulácia TOF senzora.....	9
Obr. 3-6 Mračno bodov torusu pri rozdielných pohľadoch	11
Obr. 3-7 Stavebné prvky 3D modelu pri povrchovej rekonštrukcii objektu.....	12
Obr. 3-8 Ukážka siete typu a) Polovičná hrana b) Windged-Hrana	13
Obr. 3-9 Ukážka siete Mask-Vertex.....	14
Obr. 3-10 Ukážka registrácie mračien	16
Obr. 4-1 RealSense SR300 (19).....	21
Obr. 4-2 Microsoft Kinect v2.....	22
Obr. 4-3 Model štrbinovej kamery.....	23
Obr. 4-4 Príklady radiálneho skreslenia, a) negatívne, poduškové b) bez skreslenia c) pozitívne, súdkové	25
Obr. 4-5 Príklady radiálneho skreslenia a) nulové b) nenulové.....	26
Obr. 4-6 Kalibrácia RGB obrazu, vľavo originálny obraz, vpravo kalibrovaný obraz	27
Obr. 4-7 Kalibrácia IR obrazu	27
Obr. 4-8 Kalibrácia RGB-D obrazu	28
Obr. 4-9 Kalibrácia hĺbkového obrazu.....	28
Obr. 4-10 RGB snímky statického objektu z rôznych uhlov	29
Obr. 4-11 Rekonštruované 3D modely statického objektu získané z obr. 4-10	30
Obr. 4-12 Zľava : 3D registrovaný a rekonštruovaný model , statický objekt s vybranými mernými bodmi	30
Obr. 4-13 Ukážka modelu dynamického objektu	32
Obr. 4-14 Návrh konštrukcie skenovacej komory	34
Obr. 4-15 Kalibračný stereo-pár vytvorený staticky umiestnenými kamerami	35
Obr. 4-16 Vizualizácia rozloženia kamier v spoločnom priestore získaná stereo kalibráciou	35

Obr. 4-17 Vizualizácia rozloženia kamier v spoločnom priestore získaná stereo kalibráciou pri rôznych pohľadoch	36
Obr. 4-18 Meranie TOF metódou pri viac kamerovom systéme	36
Obr. 4-19 a) 3D rekonštruovaný model s interferenciou, b) hĺbková mapa s interferenciou ..	37
Obr. 4-20 DLib-Facial Landmark Detection, 68 detekovaných bodov	37

Zoznam grafov

Graf 4-1 Absolútna chyba merania statického objektu kamerami Kinect v2 a SR300	32
Graf 4-2 Absolútna chyba merania dynamických objektov kamerou Kinect v2	32

Zoznam tabuliek

Tab. 4-1 : Tabuľka špecifikácii kamery Microsoft Kinect v2	21
Tab. 4-2 : Tabuľka nameraných hodnôt statického objektu kamerami Kinect v2 a SR300 (8)	31

Zoznam skratiek a symbolov

Skratka	Slovenský význam
μ_{ij}	Matica zhody metódy robustného párovania bodov
ADHD	Porucha pozornosti s hyperaktivitou
API	Application programming interface – užívateľské rozhranie
CAD	Počítačom podporovaný dizajn
CCW	V protismere hodinových ručičiek
CSA	Centrálne spánkové apnoe
CW	V smere hodinových ručičiek
D	Hĺbková mapa, obraz
DCEL	Polovičná dátová štruktúra
ICP	Interactive closest point
IR	Infračervený
K	Kernel
KC	Metóda korelácie kernelu
LFW	Labeled faces in the Wild Home, databáza tvári
LIDAR	Light detection and ranging
M	Pohyblivý modelový súbor
MPI	Multipath interference, interferencia vzniknutá odrazom od prostredia
OSAS	Syndróm obštrukčného spánkového apnoe
PC	Point cloud, mračno bodov
PCL	Point cloud library, knižnica pre spracovanie 3D dát
P_{M,S}	Odhad hustoty kernelu
PSG	Polysomnografia, lekárske vyšetrenie
px	pixel

Rd	Konečno-priestorový vektor
RGB-D	Červená, modrá, zelená, hĺbka
RPM	Robustné párovanie bodov
SCR	Klinický záznam o spánku
SLS	Senzor štruktúrovaného svetla
T(M), T(M, θ)	Transformačný model
TOF	Čas doby letu
WH	Winged-hrana, dátová štruktúra
γ	Regulačné parametre
θ	Optimalizačný parameter

1 ÚVOD

Syndróm obštrukčného spánkového apnoe je ochorenie, ktoré patrí medzi najčastejšie sa vyskytujúce spánkové problémy u rôznej vekovej skupiny ľudí. Komplexná diagnostika tejto poruchy prebieha v špecializovaných spánkových laboratóriách pomocou polysomnografie. Takéto vyšetrenie je však časovo a finančne nákladné, čo spôsobuje dlhé čakacie doby na vyšetrenie. Pomocným riešením je diagnostikovať rizikových pacientov, ktorí môžu byť následne uprednostnení na lekárske vyšetrenie. V praxi sa používa dotazník nazývaný „Klinický záznam o spánku“, ktorý subjektívnym spôsobom lekára určuje pravdepodobnosť ochorenia. Výsledky dotazníka sú však ovplyvnené subjektívnym hodnotením vyšetrujúceho.

Objektivizácia vyšetrenia môže byť zvýšená pomocou skríningového nástroja, ktorý by dokázal nahradiť manuálne vykonávané merania parametrov tváre predurčujúce spomínané ochorenie. V dnešnej dobe sa špecifické vlastnosti merajú manuálne kontaktnými meracími prístrojmi. Tento spôsob merania je pomalý a stresujúci predovšetkým u pediatrických pacientov. Práve stres u pacientov častokrát znemožňuje objektívny prístup k potrebným informáciám. Bezkontaktnou metódou merania by sa zvýšila objektivita a presnosť merania. Taktiež by sa znížila časová náročnosť vyšetrenia a umožnilo by sa meranie parametrov, ktoré obvykle nie sú zaznamenávané.

RGB-D kamery okrem farby dokážu zachytiť aj informáciu o hĺbke prostredia. Pomocou tejto informácie je následne možné reprodukovať geometrické vlastnosti tváre pacienta do 3D modelu. 3D rekonštrukcia objektov je technický problém, ktorý sa uplatňuje v širokom spektre od herného priemyslu cez strojárstvo až k medicíne. Práve v medicíne je 3D modelovanie interdisciplinárne. Model pacienta môže byť využívaný pri rôznych vyšetreniach bez potreby jeho prítomnosti. S využívaním umelej inteligencie vzniká aj možnosť určitého stupňa automatizácie.

O spomínaný skríningový nástroj prejavili záujem svetoví odborníci, ktorí sa špecializujú na vyšetrovanie spánkových porúch.

2 MEDICÍNSKE POZADIE VÝSKUMU

Spánkové poruchy postihujú približne 30% svetovej populácie. Podľa súčasnej platnej medzinárodnej klasifikácie spánkových porúch sú respiračné spánkové poruchy druhým najčastejším sa vyskytujúcim ochorením (1).

Respiračné spánkové apnoické ochorenia delíme na:

- obštrukčné (OSAS): dospelí pacienti, pediatrickí pacienti
- centrálné (CSA): Cheine-Stokes dýchanie, Primárne, ...
- zmiešané: kombinované CSA a OSAS

Syndróm obštrukčného spánkového apnoe (OSAS) je respiračná choroba, ktorá spôsobuje prerušenie oronazálnej ventilácie pri pretrvávajúcom dychovom úsilí na aspoň 10 sekúnd a opakuje sa viac ako 5 krát za hodinu (2). Na jej vzniku sa vo významnej miere podieľa znížená priechodnosť horných dýchacích ciest a zmena mechanizmu mäkkých štruktúr horných dýchacích ciest. Najvýznamnejším rizikovým faktorom vzniku OSAS je anatomické zúženie horných dýchacích ciest spôsobené predovšetkým: obezitou, kraniofaciálnymi abnormalitami, hypopláziou tváre, zväčšeným objemom mäkkých tkanív, hypertrofiou tonzíl, zväčšením uvuly a dĺžky mäkkého podnebia (3).

K presnému stanoveniu OSAS diagnózy sa vykonáva špeciálne komplexné vyšetrenie nazývané polysomnografia (PSG). Ide o celonočné monitorovanie pacienta pomocou snímačov a senzorov, ktoré dávajú lekárovi informáciu o dýchaní, ronchopátii, činnosti srdca, charaktere spánku a jeho jednotlivých cykloch, o polohe tela a o okysličovaní organizmu. PSG sa vykonáva v akreditovanom spánkovom laboratóriu, ktoré musí byť vybavené potrebnou meracou technikou. Z výsledkov sa následne určuje konkrétny spôsob liečby. (4)

PSG je považovaná za štandard pre diagnostiku OSAS, avšak toto vyšetrenie je finančne nákladné a časovo náročné. Navyše na Slovensku ale aj vo svete je problém s nedostatkom spánkových laboratórií, čo spôsobuje dlhé čakacie doby.

Kvôli zníženiu potreby používania PSG adolescentnou skupinou pacientov bol vytvorený validovaný dotazník nazývaný Klinický záznam o spánku (SCR). Ten pomocou kombinácie informácií z klinického vyšetrenia, skúmania subjektívnych symptómov pacienta a skúmania prítomnosti ADHD dokáže s určitou presnosťou identifikovať prítomnosť OSAS. Pozitívni pacienti sú následne uprednostňovaní na vyšetrenie PSG (5).

Vyšetrenie pomocou kontaktných meracích prístrojov je pre pediatrických pacientov často krát stresujúce. Deti sú nepokojné a nedokážu spolupracovať s doktorom, čo predlžuje vyšetrenie a vnáša chybu merania do dotazníka. Z toho dôvodu je požiadavka na vytvorenie meracieho systému, ktorý by dokázal zmerať požadované parametre bezkontaktné.

Alternatívnym riešením je vytvorenie skenovacieho zariadenia, ktoré dokáže s určitou precíznosťou geometricky aj textúrovo reprodukovat' pacienta v 3D formáte. Následné meranie na existujúcom modeli je možné vykonávať bez prítomnosti pacienta, taktiež je možné ho opakovať alebo dodatočne zmerať aj iné tvárové parametre. Pri softvérovom meraní tvárových parametrov vzniká možnosť automatizácie.

3 TECHNICKÉ POZADIE VÝSKUMU

Snahou hĺbkových kamier je zachytiť okrem informácii o farbe prostredia aj informáciu o hĺbke priestoru. V praxi to znamená, že sa transformuje 3D priestor do 2D priestoru. Táto informácia je uchovávaná v matici, ktorá je nazývaná hĺbková mapa. Spôsob vytvárania hĺbkovej mapy kamerou závisí od použitej technológie. Medzi základné spôsoby patrí stereo-vízia, snímanie štruktúrovaným svetlom (SLS) a meranie doby letu (TOF).

3.1 DISPARITNÁ A HĽBKOVÁ MAPA

Výstupný obraz zachytávajúci vzdialenosť je závislý od použitej technológie snímania. Výstupom kamery je buď disparitná alebo hĺbková mapa.

Disparita zachytáva relatívnu vzdialenosť navzájom si odpovedajúcich bodov v stereo-páre obrazu. Pri vytváraní disparity sa predpokladá s nulovou vertikálnou paralaxou. Ak teda bod v ľavom obraze na pozícii $[10,0]$ odpovedá v pravom obraze bodu $[100,0]$, tak hodnota disparity je 90.

Disparitná mapa je jedno-kanálová matica, kde každý pixel nesie informáciu o disparite. Zobrazením vzniká obraz v odtieňoch sivej, ktorý vytvára ucelenú informáciu o priestore. Disparitná mapa je vždy vytváraná pre jeden obraz z dvojice, ktorej pozícia bodu sa berie ako referencia. Takáto mapa je už pre aplikáciu v stereovízií užitočná, pretože je z nej možné odlíšiť rozloženie snímanej scény. Neposkytuje však informáciu o reálnej vzdialenosti.

Hĺbková mapa je taktiež šedo-tónový obraz, ktorý zachytáva informáciu o absolútnej vzdialenosti snímanej scény od kamery. Vytvára sa disparitnej mapy prepočtom za použitia vonkajších parametrov kamier. (6)


3.2 PRINCÍP ČINNOSTI RGB-D KAMIER

V súčasnosti sa pre vytváranie hĺbkovej mapy používajú kamery, ktoré pracujú na odlišných princípoch. V tejto práci sú opísané metódy :

- stereo-vízie: dvojica a viac RGB kamier
- snímania štruktúrovaným svetlom (SLS): Intel RealSense SR300
- merania času doby letu (TOF): Microsoft Kinect v2

3.2.1 Stereovízia

Metóda stereovízie je založená na synchronizovanom snímaní scény pomocou viacerých párov RGB kamier, ktoré sú voči sebe vzájomne posunuté. Najčastejšie rozloženia kamier sú Toe-In a Off-Axis, ktorá je znázornená na Obr. 3-1. Výstupom je farebný obraz scény zosnímanej z viacerých perspektív.




Obr. 3-1 Princíp stereovízie

Na základe rozdielu z týchto dvoch perspektív a známych vonkajších parametrov stereo-kamerovej sústavy je možné dopočítať hĺbkový obraz. Hlavnou nevýhodou je vysoká výpočtová náročnosť algoritmu a vysoká cena kvalitných snímacích RGB senzorov. Taktiež je tento systém náchylný na meniace sa svetelné podmienky, čo následne vyžaduje farebnú kalibráciu jednotlivých kamier. Výhodou je nulová vzájomná interferencia kamier.

3.2.2 SLS snímače

SLS kamery sú zložené z projektora štrukturovaného svetla a kamery. Projektor aktívne osvecuje scénu so špeciálne navrhnutým 2D vzorom, častokrát priestorovo modulovaným svetlom. Kamera následne sníma vzorom osvetlenú scénu a získané dáta porovnáva so známym vzorom. Ak je scéna planárna, snímaný vzor sa zhoduje s referenčným vzorom. Ak sú však v scéne povrchové variácie, geometrický tvar povrchu narúša projektované štrukturované svetlo a to sa nebude zhodovať s projektovaným vzorom.



Obr. 3-2 Princíp SLS kamery

Na Obr. 3.2 je znázornený geometrický vzťah medzi projektorom, kamerou a snímaným povrchom. Tento vzťah je možné vyjadriť triangulačným princípom 3.1

$$R = B \frac{\sin \theta}{\sin \alpha + \theta} \quad 3.1$$

Kľúčom k 3D zobrazovaniu na báze triangulačnej techniky je správne priradiť zosnímaný bod k projekčnému bodu (7). Na tento účel boli navrhnuté rôzne schémy, ktoré sa delia na:

- Sekvenčnú projekciu: binárny kód, šedý kód, fázový posun, hybrid
- Priebežne meniacu projekciu: dúhový kód, priebežne meniaci farebný kód
- Pásikový index: farebne kódované pásy, segmentované pásy, De Bruijn, ...
- Mriežkový index: pseudo-náhodné binárne body, mini-vzor ako kód, ...
- Hybridné metódy

Hlavnou výhodou štruktúrovaného svetla je dosiahnutie vysokého priestorového rozlíšenia. Kamery pracujúce na tomto princípe nevyžadujú žiadnu špeciálnu úpravu na úrovni snímača. Akékoľvek rušenie je znázornené ako variácie v povrchu (7). Táto metóda snímania so sebou prináša tri problémy, ktoré vyplývajú z hlavnej požiadavky, a to dôležitosti svetla:

- potreba konštantnej vlnovej dĺžky
- možné problémy spôsobené okolitými svetelnými podmienkami
- vzdialenosť limitovaná silou reflektora IR svetla

Konštantná vlnová dĺžka je zabezpečená malým Peltierovým článkom, slúžiacim na udržiavanie nemennej teploty laserovej diódy. Takým spôsobom je zabezpečená stabilná výstupná vlnová dĺžka, vzhľadom na zmeny teploty a výkonu. Osvetlenie okolitého prostredia je problémom, ktorý je možné zmierniť využitím filtra, ktorý prepúšťa iba IR frekvenčné pásmo, avšak kamera nedokáže fungovať správne na miestach osvetlených slnečným žiarením. Preto je využívanie kamier na princípe štruktúrovaného svetla výhodnejšie využívať v interiéri (8).

3.2.3 TOF snímače


Kamery pracujúce na princípe TOF produkujú hĺbkový obraz, ktorého každý pixel kóduje vzdialenosť od zodpovedajúceho bodu snímanej scény pomocou merania fázového oneskorenia infračerveného svetla. Tieto kamery patria do širšej skupiny LIDAR bez skenera, neposkytujú veľké rozlíšenie ale vysokú frekvenciu snímok (160 Hz) (9).

Medzi známe technológie TOF kamier patria:

- Photonic Mixer Devices (PMD): vzdialenosť do 60 metrov
- Swiss Ranger: vzdialenosť 5 metrov, rozlíšenie 176x144 px
- CanestaVision: výrobca technológie pre Kinect V2

Kamery obsahujú zdroj infračerveného svetla a senzor, ktorý zachytáva odrazené svetlo. Taktiež sú často kombinované s RGB snímačom, ktorý dokáže zachytiť farebnú textúru snímanej scény. Infračervené svetlo je modulované harmonicky sínusovým signálom alebo impulzne. V

praxi sa viac využíva impulzná modulácia, pretože je ľahšia na realizáciu a spracovanie. Obr. 3.3 popisuje princíp detekcie hĺbky TOF senzorom so sínusovou moduláciou.




Obr. 3-3 Princíp činnosti TOF senzorov

Infračervené svetlo s moduláciou je vyžiarené z emitora, po dopade na objekt sa odrazí a späť dopadá s fázovým oneskorením do senzora (10). Hĺbka je vypočítavaná podľa rovnice 3.2.

$$Depth = \frac{c}{2} \frac{\Delta\phi}{2\pi f} \quad 3.2$$


Pri impulznej modulácii môže byť emitované svetlo sekvenčne alebo kontinuálne (11). Na Obr. 3.3 je znázornený princíp impulznej sekvenčnej modulácie, kde je svetelný zdroj rozsvietený na krátky čas (Δt) a odrazená energia je prerozdelená na každý pixel paralelne pomocou dvoch fázových okien C1 a C2 s rovnakým trvaním Δt . Elektrické náboje, ktoré sa nahromadili počas týchto vzoriek, Q_1 a Q_2 , sú merané a použité na výpočet vzdialenosti pomocou vzťahu 3.3:

$$Depth = \frac{c}{2} \cdot \Delta t \left(\frac{Q_2}{Q_1 + Q_2} \right) \quad 3.3$$



Obr. 3-4 Sekvenčná impulzná modulácia TOF senzora

Metóda s použitím kontinuálnej vlny obsahuje viac vzoriek pre jedno meranie, pričom každá vzorka je posunutá s fázovým oneskorením o 90°. Meranie fázového rozdielu medzi vyžarovanými a odrazenými IR vlnami je zabezpečené prepočtom vzdialenosti od objektu na základe vzťahu 3.4 medzi štyrmi rôznymi hodnotami elektrického náboja.



Obr. 3-5 Kontinuálna impulzná modulácia TOF senzora

Pomocou tejto techniky je vypočítaný fázový uhol $\Delta\varphi$ medzi osvetlením a odrazom. Tento fázový posun je následne prepočítaný na hĺbku.

$$\Delta\varphi = \tan^{-1} \left(\frac{Q_3 - Q_4}{Q_1 - Q_2} \right) \quad 3.4$$

K spresneniu merania a eliminácii vplyvu akejkoľvek konštanty posunutia od merania sa z prijatých odrazov počíta amplitúda intenzity A 3.5 a offset B 3.6:

$$A = \frac{\sqrt{(Q_1 - Q_2)^2 + (Q_3 - Q_4)^2}}{2} \quad 3.5$$

$$B = \frac{Q_1 + Q_2 + Q_3 + Q_4}{4} \quad 3.6$$

Amplitúda intenzity A a ofset B majú vplyv na presnosť merania hĺbky. Odchýlku merania hĺbky je možné aproximovať podľa vzťahu 3.7:


$$\sigma = \frac{c}{4\sqrt{2\pi f}} \cdot \frac{\sqrt{A+B}}{c_d A} \quad 3.7$$

v nej modulačný kontrast c_d opisuje ako efektívny zobrazovací kremík oddeľuje a zbiera fotoelektróny. Amplitúda intenzity A je funkciou optickej sily a offset B je funkciou okolitého svetla. Z tejto rovnice možno vyvodiť, že vysoká odrazená amplitúda, frekvencia vysokej modulácie a kontrast s vysokou moduláciou prispievajú k zvýšeniu presnosti. Vysoký offset na druhej strane môže viesť k sýtosti a zníženiu presnosti. Snímače TOF s vysokou odchýlkou všeobecne prinášajú vyššiu presnosť (12).

Hlavnou výhodou TOF kamier je používanie iba jedného pohľadu pri výpočte hĺbky, vďaka čomu sú zachované ostré hrany objektov a redukovaná prítomnosť otvorov vo výslednom obraze, pričom je zanechaná vysoká presnosť údajov. Hustotu nameraných dát je možné ovplyvniť počtom meraní. Výhodou je aj to, že okolité osvetlenie už neovplyvňuje zaznamenávanie obrazu, pretože nedochádza k ovplyvňovaniu frekvencie vyžarovaného svetla. K ďalším kladným vlastnostiam patrí vysoký dynamický rozsah a absencia cenovo náročných materiálov v zariadení. Medzi nevýhody kamier s TOF zaradíme nižšiu kvalitu priestorového rozlíšenia, zapríčinenú extra spracovaním na úrovni snímača, a taktiež náchylnosť na pohybové artefakty pri viacnásobnom počte záberov. Pri kamere využívajúcej TOF je potrebné vopred vedieť rýchlosť šírenia signálu v danom prostredí. Namerané výsledky sú závislé aj od materiálu meraného subjektu. Pri nevhodnom materiáli môže dochádzať k niekoľkonásobnému odrazu. Negatívne vlastnosti TOF sa prejavujú prevažne na okrajových pixloch (13).

3.3 MRAČNO BODOV A 3D POVRCH


Pri reprojekcii 3D priestoru z 2D obrazu sa často používa technológia mračien bodov (PC). Základnou jednotkou mračna bodov je dátový bod, ktorý v sebe ukladá informáciu o polohe (x,y,z) v 3D priestore. Dátový bod môže v sebe uchovávať aj iné informácie ako napríklad farbu, jas, normálový vektor a podobne. Takéto mračno bodov má veľké využitie v priemyselných 3D CAD modeloch, pri metrológii a inšpekcií kvality a v iných sférach, kde sa vizuálne prezentujú 3D objekty. Výhodou oproti 2D zobrazovaniu je, že 3D model dokáže poskytnúť lepšiu vizuálnu informáciu pre užívateľa, kde si užívateľ vie vybrať vlastný pohľad a natočenie objektu.



Obr. 3-6 Mračno bodov torusu pri rozdielnych pohľadoch

Prevod PC na 3D povrch je realizovaný pomocou rekonštrukcie povrchu (anglicky surface reconstruction). Medzi známe rekonštrukčné metódy patrí Ball-Pivoting a Poissonova rekonštrukcia, kde sú dátové body transformované do siete. Polygonová sieť je zložená z vertexov (vertices), hrán (edges) a masiek (faces), taktiež definuje tvar polyhedrálneho objektu v 3D grafike. Masky sa zvyčajne skladajú z trojuholníkov, štvorhranov a iných jednoduchých konvexných polygónov. Volumetrické siete explicitne reprezentujú povrch aj objem štruktúry, pričom polygonová sieť reprezentuje iba povrch. Objekty vytvorené z polygónov musia ukladať rôzne typy elementov. To zahŕňa vertexy, hrany, masky, polygóny a povrchy. Veľakrát sú polygóny transformované na trojuholníky, pretože viacstranové polygóny nie sú podporované. Pri modelovaní hlavy sú však potrebné viacstranové polygóny (14).

- Vertex: Dátový bod, informácia o polohe poprípade farbe a normále
- Hrana: Spojenie medzi dvomi vertexmi
- Maska: Polygón zložený z najbližších hrán
- Povrch: Skupina polygónov, ktorá vytvára povrch objektu.



Obr. 3-7 Stavebné prvky 3D modelu pri povrchovej rekonštrukcii objektu

Sieť polygónov môže byť reprezentovaná rôznymi spôsobmi, kde sú vertexy, hrany a masky ukladané pomocou rôznych metód. Medzi základné patrí :

Sieť typu Winged-Edge:


Táto dátová štruktúra je používaná na opis polygónových modelov v počítačovej grafike. Opisuje explicitne geometriu a topológiu masiek, hrán a vertexov, keď sa stretnú tri a viac povrchov na spoločnej hrane. Povrchy sú usporiadané proti smeru hodinových ručičiek vzhľadom na vrodenu orientáciu priesečníka. Reprezentácia umožňuje spracovanie nestabilných číselných situácií. Známa metóda používajúca WH dátovú štruktúru je **Subdivision surface**. Táto štruktúra umožňuje rýchle dynamické prechody medzi maskami, hranami a vertexmi v dôsledku explicitne prepojenej štruktúry siete (15).

Sieť typu Half-Edge:

Polovičná dátová štruktúra (označovaná aj DCEL) reprezentuje vloženie rovinného grafu do roviny a polytopety v 3D. Táto dátová štruktúra umožňuje efektívnu manipuláciu s vertexmi, hranami a maskami. Každá polovičná hrana má presne jednu predchádzajúcu a nasledujúcu polovičnú hranu a dvojité hranu (16).

Štvorhranná sieť:

Táto štvorhranná štruktúra uchováva informácie o dvoch vertexoch, dvoch maskách a 4 hranách. Štyri uložené hrany začínajúce dvoma vrcholmi sú pripojené k dvom uloženým maskám. Základnou myšlienkou štruktúry je rozpoznanie jednej hrany v uzavretej polygórovej topológii, ktorá leží presne medzi dvoma plochami a dvoma vrcholmi. Takto môže predstavovať dvojité graf jednoduchým obrátením konvencie o tom, čo je vertex a čo je maska (17).



Obr. 3-8 Ukážka siete typu a) Polovičná hrana b) Windged-Hrana

Sieť typu Vertex-vertex:

Sieť reprezentuje vertexy, ktoré ukazujú na iné vertexy. Informácia o hrane a maske je implicitne uložená v zobrazení. Jednoduchosť zobrazenia neumožňuje vykonávanie efektívnych operácií na sieti, ale pri spracovaní je potrebný vyšší výpočtový výkon. Výhodou je malá spotreba úložného miesta a efektívneho tvarovania tvarov (14).

Sieť typu Rohové stoly:


V tomto prípade sú ukladané vertexy v preddefinovanej tabuľke tak, že prichádzajúce tabuľky implicitne definujú polygóny. Takýto typ štruktúry je využívaný pri vykresľovaní hardvérovej grafiky cez trojuholníky. Reprezentácia je kompaktnejšia a efektívnejšia na získavanie polygónov, ale operácie na zmenu polygónov sú pomalé.

Každé z vyššie uvedených spôsobov zobrazenia siete má osobitné výhody a nevýhody, o ktorých sa ďalej diskutuje v (14).

Sieť typu Maska-Vertex:

Sieťové tváre predstavujú objekt ako sadu masiek a množinu vertexov. Toto je najrozšírenejšia sieťová reprezentácia, ktorá je vstupom typicky akceptovaným moderným grafickým hardvérom.

Maska-Vertex siete sú oproti Vertex-Vertex siete lepšie pre modelovanie v tom, že umožňujú explicitné vyhľadávanie vertexov masiek a masky obklopujúce vertex. Obr. 3-9 znázorňuje príklad "box-cylinder" ako sieť maska-vertex. Vertex v5 je zvýraznený na zobrazenie masiek, ktoré ho obklopujú. V tomto prípade sa vyžaduje, aby každá maska mala presne tri vertexy. To však neznamená, že každý vertex má rovnaký počet obklopujúcich masiek (14).



Obr. 3-9 Ukážka siete Maska-Vertex

3.4 SPÁJANIE A REGISTRÁCIA MRAČIEN BODOV

Bodová registrácia tiež známa ako bodová zhoda je proces, pri ktorom sa hľadá priestorová transformácia zosúladujúca dve mračná bodov. Účelom transformácie je zlúčenie viacerých mračen do jedného konzistentného modelu. Mračná môžu byť získané rôznymi typmi snímačov a rôznymi spôsobmi. Niektoré typy snímačov boli opísané v kapitole 3.2. Pre získanie priestorovej transformácie existuje viacero algoritmov, ktoré sú opísané nižšie.

3.4.1 Problematika registrácie mračen bodov

Problematika registrácie mračen bola opísaná v práci „Robust Point Set Registration Using Gaussian Mixture Models“, autormi Bink Jian, Baba C. Verumi. Nech $\{M, S\}$ sú dva konečné mračná bodov v konečne-rozmernom reálnom vektorovom priestore. M označuje pohyblivý modelový súbor a S označuje statickú scénu. Obe množiny sa označujú ako podmnožiny konečno-priestorového vektora \mathbf{R}_d a môžu mať rozdielne veľkosti. Spoločným približovaním sa (registráciou) bodových množín M a S je možné odhadnúť mapovanie z \mathbf{R}_d do \mathbf{R}_d , čo prináša najlepšie zarovnanie medzi transformovanou a statickou sadou bodov. Transformačný model môže byť zapísaný ako $\mathbf{T}(\mathbf{M})$ alebo $\mathbf{T}(\mathbf{M}, \boldsymbol{\theta})$, kde $\boldsymbol{\theta}$ predstavuje optimalizačný parameter. Pri konvergencii bodov M a S je žiadané, aby vzdialenosť medzi zhodnými bodovými súbormi bola čo najmenšia. To je však bez vyskúšania všetkých transformácií ťažké, takže stačí lokálne minimum. Funkcia vzdialenosti medzi transformovaným dátovým setom a scénou S je daná niektorou z funkcií *dist*. Jednoduchým spôsobom je výpočet štvorca euklidovskej vzdialenosti pre každý pár bodov:

$$dist(T(M), S) = \sum_{m \in T(M)} \sum_{s \in S} (m - s)^2 \quad 3.8$$

Táto funkcia je náchylná voči šumovým dátam. Robustnosť g sa môže doceliť M-estimátorom, ktorý dokáže odfiltrovať extrémne hodnoty (17):

$$dist_{robust}(T(M), S) = \sum_{m \in T(M)} \sum_{s \in S} g((m - s)^2) \quad 3.9$$

3.4.2 Spôsoby registrácie mračien bodov


Spôsoby registrácie môžeme rozdeliť do dvoch kategórií. Prvou je pevná (rigidná) druhá voľná (nerigidná) registrácia. Pri **rigidnej** registrácii sa používajú rotačné a translačné transformácie k namapovaniu jedného bodu na druhý. Táto transformácia je definovaná tak, že nemení vzdialenosť medzi dvoma bodmi. V zriedkavých prípadoch môže byť bodový súbor tiež zrkadlový. **Voľná registrácia** vzhľadom na dva bodové súbory prináša transformáciu, ktorá mapuje jeden bod nastavený na druhý. V transformáciách sú zahrnuté afinné transformácie, ktoré zahŕňajú aj nelineárne transformácie. Ak sú známe vlastné modifikácie množiny bodov, nelineárna transformácia môže byť parametrizovaná vlastnými hodnotami.

Bodové registračné algoritmy:

K bodovej registrácii sa používajú algoritmy, ktoré riešia všeobecnejší problém s porovnávaním grafov. Avšak výpočtová zložitosť zvykne byť vysoká a obmedzená na rigidné registrácie.

Iterative closest point:

ICP algoritmus je používaný na minimalizáciu rozdielu medzi dvoma mračnami bodov. Využíva sa na rekonštrukciu 2D a 3D povrchov, lokalizáciu robotov a podobne. Vykonáva rigidnú registráciu interačným spôsobom za predpokladu, že každý bod v M korešponduje s najbližším bodom v S . V algoritme sa hľadá transformácia T pomocou metódy najmenších štvorcov.



Obr. 3-10 Ukážka registrácie mračien

Robustné párovanie bodov

Túto metódu (RPM) zaviedli Gold a kolektív (19). Táto metóda pracuje na zašumených 2D alebo 3D bodových setoch, ktoré môžu mať rozličné veľkosti a môžu sa líšiť pri voľných transformáciách. Pomocou kombinácie optimalizačných techník ako „deterministic annealing“ a „softassing“, ktoré boli objavené pri rekurentných neurónových sieťach, sú analógové objektové funkcie popisujúce problémy minimalizované. Zatiaľ čo v ICP je korešpondencia vytvorená najbližším heuristickým binárnym systémom, RPM používa mäkkú korešpondenciu bodov. To znamená, že korešpondencia bodov môže byť ľubovoľná v rozmedzí 0 a 1. Zhoda v RPM je vždy jedna k jednej, čo pri ICP metóde nie je zabezpečené. Ak m_i je i -ty bod množiny M a s_j je j -ty bod množiny S , tak matica zhody μ je definovaná ako:

$$\mu_{ij} = \begin{cases} 1 & \text{ak bod } m_i \text{ korešponduje s bodom } s_j \\ 0 & \text{v inom prípade} \end{cases} \quad 3.10$$

Riešením je nájsť afinnú transformáciu T , pri ktorej bude matica μ vykazovať najvyššiu zhodu (19). Znalosť optimálnej transformácie umožňuje ľahko určiť maticu zhody a naopak. Robustným párovaním bodov je možné určiť obe veci súčasne. Transformácia sa môže rozložiť na translačný vektor a transformačnú maticu.

$$T(m) = \bar{A}m + \bar{t} \quad 3.11$$

Matica \mathbf{A} sa skladá zo štyroch samostatných parametrov $\{a, \theta, b, c\}$, ktoré spôsobujú zmenu veľkosti, rotáciu, horizontálnu a vertikálnu geometrickú transformáciu.

Hodnotová funkcia je reprezentovaná rovnicou 3.12 pričom v nej platí podmienka 3.13:

$$cost = \sum_{j=1}^N \sum_{i=1}^M \mu_{ij} \|s_j - \mathbf{t} - \mathbf{A}m_i\|^2 + \mathbf{g}(\mathbf{A}) - \alpha \sum_{j=1}^N \sum_{i=1}^M \mu_{ij} \quad 3.12$$

$$\forall j \sum_{i=1}^M \mu_{ij} \leq 1, \forall i \sum_{j=1}^N \mu_{ij} \leq 1, \forall ij \mu_{ij} \in \{0,1\} \quad 3.13$$

Parameter α ovplyvňuje funkciu k silnejšej korelácie. Funkcia $g(A)$ slúži na reguláciu afinnej transformácie penalizovaním veľkých hodnôt transformovaných komponentov. Pre niektoré regulačné parametre γ platí $g(A(a, \theta, b, c)) = \gamma(a^2 + b^2 + c^2)$. Táto metóda RPM optimalizuje hodnotovú funkciu použitím „Softassign“ algoritmu.

Korelácia kernelu

Metóda korelácie kernelu (KC) je oproti ICP metóde odolnejšia voči zašumeným dátam. Na rozdiel od ICP, v tejto metóde každý bod scény uvažuje s modelovým bodom. Ide o viacnásobne prepojujúcu registráciu (18). Pre niektoré funkcie kernelu K je KC dvoch bodov x_i a x_j definovaná nasledovne:

$$KC(x_i, x_j) = \int K(x, x_i) \cdot K(x, x_j) dx \quad 3.14$$

Funkcia K zvolená pre bodovú registráciu je typický symetrický a nenegatívny kernel. Zvyčajne je používaný Gaussov kernel pre svoju jednoduchosť, avšak časté sú aj Epanechnikov a tricube kernel (18). Korelácia kernelu celej množiny bodov χ je definovaná ako súčet korelácií kernelu každého bodu v množine s každým ďalším bodom v množine.

$$KC(\chi) = \sum_{i \neq j} KC(x_i, x_j) = 2 \sum_{i < j} KC(x_i, x_j) \quad 3.15$$

Hodnota KC množiny bodov je proporcionálna v rámci konštantného faktora logaritmu informačnej entropie. KC je v podstate mierou kompaktnosti bodu, ktorý je triviálne nastavený. Ak by sa všetky body nachádzali v jednom mieste, KC by nadobudol veľkú hodnotu. Hodnotová funkcia (cost) dátovej množiny pre určité transformačné parametre θ je definovaná nasledovne :

$$\text{cost}(S, M, \theta) = - \sum_{m \in M} \sum_{s \in S} KC(s, T(m, \theta)) \quad 3.16$$

Niektoré algebrické manipulácie sú opísané rovnicou 3.17:

$$KC(S \cup T(M, \theta)) = KC(S) + KC(T(M, \theta)) - 2\text{cost}(S, M, \theta) \quad 3.17$$

Výraz je zjednodušený tým, že sa pozoruje $KC(S)$ nezávisle od θ . Ak sa ešte uvažuje s rigidnou registráciou, $KC(T(M, \theta))$ je tým pádom invariantný voči zmene θ , pretože Euklidovská

vzdialenosť medzi párom bodov sa pri rigidnej transformácii nemení. Tým pádom je rovnicu 3.17 možné prepísať na 3.18:

$$KC(S \cup T(M, \theta)) = C - 2\text{cost}(S, M, \theta) \quad 3.18$$

Estimácia hustoty kernelu je neparametrický spôsob odhadovania hustoty pravdepodobnosti náhodnej premennej. Odhad hustoty kernelu je základným problémom vyhladzovania údajov na základe dátovej vzorky. Jej definícia pre tento prípad je znázornená v rovniciach 3.19 a 3.20.

$$P_M(x, \theta) = \frac{1}{M} \sum_{m \in M} K(x, T(m, \theta)) \quad 3.19$$

$$P_S(x) = \frac{1}{N} \sum_{s \in S} K(x, s) \quad 3.20$$

Hodnotovú funkciu následne možno dokázať ako koreláciu odhadov hustoty kernelu.

$$\text{cost}(S, M, \theta) = -N^2 \int_x (P_M P_S) \quad 3.21$$

Po získaní hodnotovej funkcie algoritmus používa zostup gradientu, čo je iteračný optimalizačný algoritmus prvého radu na zistenie minimálnej funkcie. Ním sa nachádza optimálna transformácia. Z dôvodu výpočtovej náročnosti sa používa diskretná verzia funkcie 3.18 cost. Oproti ICP algoritmu KC metóda nepotrebuje nájsť najbližšieho suseda a tým pádom je ľahšia na implementáciu. Taktiež je menej náchylná na šum v dátach (18).

4 MOŽNOSTI SKENOVANIA OBJEKTŮV

Skenovanie môže byť vykonávané rôznymi spôsobmi. Medzi základné patria :

- jednokamerový
statická kamera - pohyblivý objekt, statický objekt - pohyblivá kamera
- viackamerový systém
statický objekt - statická kamera

V prvom bode je hlavným rozdielom počet použitých kamier. Pri jedno-kamerovom systéme sa používa len jedna kamera, ktorá musí zachytiť snímaný objekt z požadovaných uhlov. To je možné zabezpečiť otáčaním kamery okolo statického objektu alebo otáčaním objektu okolo statickej kamery. Skenovanie jednou kamerou je z časového hľadiska náročnejšie. Pacient počas skenovania nepredstavuje statický objekt ale dynamický. Preto je aj presnosť modelu obmedzená schopnosťou pacienta nemeniť svoju pózu.

Pri viackamerovom systéme sú kamery rozmiestnené v priestore tak, aby zachytili všetky potrebné detaily. Skenovanie je rýchlejšie, avšak náročnejšie na hardvérové a softvérové vybavenie. Jednou z podmienok je statické uloženie kamier a ich presná vzájomná priestorová kalibrácia.

Pre skenovanie boli používané RGB-D kamery Kinect v2 od firmy Microsoft a kameru RealSense SR300 od firmy Intel.

4.1 INTEL REALSENSE SR300

Kamera RealSense SR300 predstavuje vylepšenie v porovnaní s predošlou, staršou verziou RealSense F200, ale stále je to snímač, ktorý je radený do kategórie nízko-nákladových. Novší model má vylepšený hĺbkový rozsah od 0,2 m do 1,5 m, preto je známa aj ako kamera s krátkym dosahom. Poskytuje dynamické snímanie pohybu a má vyššiu výpovednú hodnotu údajov pri redukovanej spotrebe energie (8). Kamera zaznamenáva farebný obraz o veľkosti

1920 × 1080 pixelov v plnom HD rozlíšení s 30 Hz. Hĺbkový obraz predstavuje 640 × 480 pixelov vo VGA. Rozmery kamery SR300 sú približne 1100 mm × 12,5 mm × 3,75 mm.



Obr. 4-1 RealSense SR300 (19)

Súčasťou kamery sú štyri komponenty ako klasická RGB kamera, IR kamera, IR laserový projektor a pole mikrofónov. IR laserový projektor sa využíva na premietanie mriežky na scénu (20).

4.2 MICROSOFT KINECT V2

Kinect v2 od spoločnosti Microsoft predstavuje druhú generáciu, pri ktorej je výrazné zlepšenie presnosti merania hĺbky. Na meranie hĺbky je použitá metóda merania doby letu TOF využívajúca aktívne senzory na meranie vzdialenosti povrchu výpočtom odrazivosti štruktúrovaného svetla v IR oblasti. Rozlíšenie kamery pre farebný obraz predstavuje 1920 × 1080 pixelov a pre hĺbkový obraz 512 × 424 pixelov, pri 50 snímkach za sekundu s chybou odhadnutia hĺbky menšou ako 1%.

Tab. 4-1 : Tabuľka špecifikácii kamery Microsoft Kinect v2

Kinect v2	Špecifikácie
Princíp merania hĺbky	meranie doby letu
Rozlíšenie RGB kamery	1920 × 1080
Rozlíšenie IR kamery	512 × 424
Počet snímok za sekundu	30
Min. dosah	0,5 m
Max. dosah	4,5 m

V tejto verzii je dosiahnutá vyššia presnosť merania a je redukovaný aj problém snímania na priamom slnečnom svetle (8). Snímač hĺbky využíva metódu TOF, ktorá bola opísaná v kapitole 3.2.3. Podľa farby, odrazivosti a geometrickej štruktúry cieľového objektu odrazené IR svetlo zobrazuje amplitúdu a fázové zmeny, ktoré môžu spôsobovať hĺbkové chyby.



Obr. 4-2 Microsoft Kinect v2

Druhá generácia je schopná zaznamenávať objekty v rozsahu 0,5 – 4,5 m. Kinect 2 obsahuje referenčný signál, ktorý moduluje na modulačnej frekvencii ω (v rozsahu 50 – 150 MHz). Keď optický signál zasiahne objekt a vráti sa do kamery, krivka je posunutá vo fáze od referenčného signálu. Svetelný zdroj emituje signál so spojitou periodickou vlnou. Po odrazení od objektu v určitej vzdialenosti dochádza k zmene formy signálu (8).

4.3 KALIBRÁCIA KAMIER


Kalibráciu delíme na geometricnú a viackamerovú. Geometrická kalibrácia kamery odhaduje parametre objektívu a obrazového snímača obrazu alebo videokamery. Tieto parametre sa používajú na korekciu skreslenia šošoviek, meranie veľkosti objektov v SI jednotkách. Viackamerová kalibrácia slúži na určenie polohy kamery v scéne. Obe kalibrácie sa používajú v aplikáciách, ako je strojové videnie na detekciu a meranie objektov. Taktiež aj v oblasti robotiky, navigačných systémov a pri 3D rekonštrukcii.

Parametre kamery sa skladajú z vnútorných (intrinsických), vonkajších (extrinsických) koeficientov a koeficientov skreslenia (distortion). K určeniu je potrebné mať 3D body scény (world points) a ich zodpovedajúce 2D body. Získanie týchto korešpondujúcich dát je možné extrakciou ľahko identifikovateľných bodov. Jedným z najpoužívanejších kalibračných vzorov je šachovnica, kde je výrazný farebný prechod medzi hracími poľami (8).

Z kalibrácie je možné získať informácie o:

- relatívnej polohy fotoaparátu a snímaného objektu
- chybe reprojekcie 3D objektu v 2D rovine
- chybe estimácie parametrov

Ku kalibrácii sa používa model štrbinovej kamery (pinhole camera model) a skreslenie šošoviek. Model štrbinovej kamery nezohľadňuje skreslenie šošoviek, pretože ideálna kamera nemá objektív (21).



Obr. 4-3 Model štrbinovej kamery

Parametre kamery sú reprezentované maticou s rozmerom 4x3 nazývanou matica kamery (P). Táto matica mapuje 3-D scénu do roviny obrazu. Kalibračný algoritmus vypočítava túto maticu s použitím vonkajších a vnútorných parametrov. Vonkajšie parametre predstavujú umiestnenie kamery v 3D scéne a vnútorné ohniskovú vzdialenosť kamery a optický stred (cx,cy).

Rovnica 4.1 reprezentuje prepojenie 2D roviny a 3D scény. Parameter s je pomerový faktor, body [u,v,1] sú body 2D roviny a body [X,Y,Z,1] sú body 3D scény:

$$s \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = P \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix} \quad 4.1$$

Matica kamery P sa skladá z vnútorných a vonkajších parametrov. Matica R zastupuje rotáciu a t transláciu, čo sú vonkajšie parametre. Matica K zastupuje vnútorné parametre (21):

$$s \begin{bmatrix} R \\ t \end{bmatrix} K = \begin{bmatrix} r_{11} & r_{12} & r_{13} & t_1 \\ r_{21} & r_{22} & r_{23} & t_2 \\ r_{31} & r_{32} & r_{33} & t_3 \end{bmatrix} \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \quad 4.2$$

- $[X,Y,Z]$: sú body v 3D súradnicovom priestore
- $[u,v]$: sú súradnice projekčného bodu v pixeloch
- P : matica kamery reprezentovaná vnútornými a vonkajšími parametrami
- c_x, c_y : hlavný bod, zvyčajne v strede obrazu, vnútorné parametre
- f_x, f_y : ohniskové vzdialenosti vyjadrené v jednotkách pixelov, vnútorné parametre
- r_{xx} : rotačné parametre kamery
- t_x : translačné parametre kamery
- s : pomerový faktor (scale factor)

Ak je teda obraz z kamery zmenený faktorom s , všetky parametre by mali byť násobené/delené o rovnaký faktor. Matica vnútorných parametrov nezávisí od zobrazenej scény, takže pri statickej ohniskovej vzdialenosti bude konštantná. Ak z je rozdielne od 0, tak transformácia 4.2 pri modeli štrbinovej kamery je ekvivalentná 4.3. Odvodenie rovnice je od 4.4 do 4.7:

$$\begin{bmatrix} u \\ v \\ z \end{bmatrix} K = R \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} t \quad 4.3$$


$$x' = x/z \quad 4.4$$

$$y' = y/z \quad 4.5$$

$$u = f_x x' + c_x \quad 4.6$$

$$v = f_y y' + c_y \quad 4.7$$

V reálnych kamerách sa vyskytuje radiálne a tangenciálne skreslenie. Radiálne skreslenie je spôsobené, keď sa svetelné lúče ohnú viac v blízkosti okrajov šošovky ako v optickom centre. Čím je objektív menší, tým väčšie je skreslenie. Typické radiálne skreslenia sú súdkové a poduškové, ktoré sa nachádzajú na obr. 4-4 (22).



Obr. 4-4 Príklady radiálneho skreslenia, a) negatívne, poduškové b) bez skreslenia c) pozitívne, súdkové

Koeficienty radiálneho skreslenia modelujú tento typ skreslenia. Deformované body sú označené ako x' a y' . Prvky k1-6 predstavujú koeficienty radiálneho skreslenia (23):

$$x' = x \frac{1 + k_1 r^2 + k_2 r^4 + k_3 r^6}{1 + k_4 r^2 + k_5 r^4 + k_6 r^6} \quad 4.8$$


$$y' = y \frac{1 + k_1 r^2 + k_2 r^4 + k_3 r^6}{1 + k_4 r^2 + k_5 r^4 + k_6 r^6} \quad 4.9$$

Neskreslené pixely označené x, y sa nachádzajú v normalizovaných súradniciach obrázka. Normalizované súradnice sú vypočítané zo súradníc pixelov preložením do optického stredu a prepočítané pomocou ohniskovej vzdialenosti v pixeloch. Takže x a y sú bezrozmerné. Prvok $r^2 = x^2 + y^2$. Ak je $k_1 < 0$, tak je skreslenie súdkovité a ak $k_1 > 0$, tak ide o skreslenie poduškovité. Koeficienty k_3 a vyššie sú pri bežných deformáciách zvyčajne rovné 0. Prejavujú sa prevažne pri širokouhlých objektívoch.

Tangenciálne skreslenie vzniká pri neparalelnom umiestnení senzora kamery so šošovkou. Prvky p_1 a p_2 sú koeficienty tangenciálneho skreslenia šošovky:

$$x' = 2p_1 xy + p_2(r^2 + 2x^2) \quad 4.10$$

$$y' = p_1(r^2 + 2y^2) + 2p_2 xy \quad 4.11$$



Obr. 4-5 Príklady radiálneho skreslenia a) nulové b) nenulové

Model štrbinovej kamery rozšírený o korekciu tangenciálneho a radiálneho skreslenia je nasledovný (24):

$$\begin{bmatrix} u \\ v \\ z \end{bmatrix} = R \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} + t \quad 4.12$$

$$x' = x/z \quad 4.13$$

$$y' = y/z \quad 4.14$$

$$x'' = x' \frac{1 + k_1 r^2 + k_2 r^4 + k_3 r^6}{1 + k_4 r^2 + k_5 r^4 + k_6 r^6} + 2p_1 xy + p_2 (r^2 + 2x^2) \quad 4.15$$

$$y'' = y' \frac{1 + k_1 r^2 + k_2 r^4 + k_3 r^6}{1 + k_4 r^2 + k_5 r^4 + k_6 r^6} + p_1 (r^2 + 2y^2) + 2p_2 xy \quad 4.16$$

$$r^2 = x^2 + y^2 \quad 4.17$$

$$u = f_x x' + c_x \quad 4.18$$

$$v = f_y y' + c_y \quad 4.19$$


RGB-D kamery kalibrujeme z dôvodu získania čo najprecíznejšej hĺbkovej mapy a taktiež z dôvodu čo najvernejšej registrácie RGB obrazu na D obraz. Prvým krokom je geometrická

kalibrácia, kde sa zisťujú vnútorné parametre kamery a koeficienty radiálneho a tangenciálneho skreslenia. Táto kalibrácia je vykonávaná na RGB a IR obraze (25), (26).

Na obr. 4-6 až 4-9 sa nachádzajú originálne a kalibrované obrazy získane z Kinect v2. Pri detailnejšom pohľade je vidieť, že v originálnych obrazoch prevládalo poduškové skreslenie. To sa najviac prejavovalo v rohoch a vytváralo efekt zvaný „rybie oko“. Po kalibrácii je skreslenie minimalizované.



Obr. 4-6 Kalibrácia RGB obrazu, vľavo originálny obraz, vpravo kalibrovaný obraz




Obr. 4-7 Kalibrácia IR obrazu

Z IR kalibrovaného obrazu je vytváraný hĺbkový obraz, ktorý reprezentuje vzdialenosť objektov v prostredí. Stereo kalibráciou sa dostávajú rotačné a translačné parametre pre dvojicu IR a RGB, ktorými sa následne registruje jeden obraz do druhého a získava sa RGB-D obraz (27).



Obr. 4-8 Kalibrácia RGB-D obrazu



Obr. 4-9 Kalibrácia hĺbkového obrazu

Kalibráciu hĺbkovej mapy robíme pomocou RGB-D obrazu, pretože samotná hĺbková mapa neposkytuje informáciu o prechode farieb. Tým pádom nie je možné extrahovať kalibračné body a vykonať kalibráciu. V precízne registrovanej RGB-D mape sa farebné pixely zachytávajúce prostredie zhodujú s pixelmi hĺbkovej mapy. Tým pádom sa kalibrácia môže vykonávať na RGB-D obraze a výsledné kalibračné parametre budú použiteľné aj pre D obraz. RGB-D a hĺbkový obraz poskytuje informácie potrebné k 3D rekonštrukcii snímaného prostredia.

4.4 JEDNOKAMEROVÝ SYSTÉM

Pri testovaní jedno-kamerového systému boli využívané kamery Kinect v2 a RealSense SR300. Testovanie pozostávalo zo skenovania statického a dynamického modelu, na ktorom boli merané zaujímavé parametre. Cieľom testovania bolo porovnať presnosť 3D rekonštrukcie voči reálnym objektom. Systém bol založený na princípe skladania snímok pomocou registračnej metódy ICP. Pomocou programov, určených k práci s jednotlivými kamerami, bola vytvorená séria 3D modelov hlavy. Hlava bola zachytená z rôznych uhlov tak, aby fotky obsahovali všetky potrebné detaily. Prvá snímka bola zachytená pri pohľade spredu, druhá zboku z pravej strany a následne posledná zboku z ľavej strany, pri rovnakom uhlovom natočení vzhľadom na prvú snímku. Natočenie bolo zvolené kvôli zabezpečeniu potreby identických bodov na snímkach. Na obr. 4-10 sa nachádzajú ukážky snímok vytvorených kamerou Kinect v2.



Obr. 4-10 RGB snímky statického objektu z rôznych uhlov

Dáta zo snímania boli vo formáte Mask-Vertex, v ktorom boli ďalej spracovávané. Ďalšie spracovanie dát bolo realizované v programe MeshLab (8). Jednotlivé modely obsahovali nepotrebné časti objektu, ktoré bolo potrebné orezať. Po jeho eliminácii ostali len objekty, ktoré boli použité na zjednotenie troch modelov hlavy do jednej (obr. 4-11).



Obr. 4-11 Rekonštruovane 3D modely statického objektu získané z obr. 4-10

Ďalším krokom bolo zjednotenie snímok do jednej a vytvorenie modelu hlavy, ako je to znázornené na obr. 4-12. Pri zjednocovaní snímok cez MeshLab → Align bolo potrebné zvoliť snímku, ktorá by predstavovala referenciu, na základe ktorej budú pridávané ďalšie snímky. Snímka frontálnej časti tváre najviac vyhovovala požiadavkám. Ďalším krokom bolo zvolenie minimálne štyroch bodov, ktoré by boli identické v oboch vzájomne spájaných snímkach: stred medzi obočím, špička nosa, stred pery, hrana brady, stred oka a stred líca. Po potvrdení program sám uskutočnil transláciu a rotáciu snímky vzhľadom na snímku, ktorá bola označená ako referenčná. Tento postup bol vykonaný spolu dvakrát, aby bolo zabezpečené spojenie oboch bočných strán s prvou snímkou. Nevýhodou tohto postupu je potreba manuálnej špecifikácie spoločných bodov (8).



Obr. 4-12 Zľava : 3D registrovaný a rekonštruovaný model , statický objekt s vybranými mernými bodmi


Presnosť 3D modelu bola zisťovaná porovnávaním skutočných vzdialeností špecifických bodov skenovaného objektu voči vzdialenostiam tých istých špecifických bodov na modeli. Vybrané body sú zobrazené na obr. 4-12 a boli vybrané na základe vzoru štúdie (28). K identifikácii špecifických bodov boli počas skenovania použité zvýrazňovacie prvky. Meranie na modeli bolo uskutočnené nástrojom Measuring Tools v programe MeshLab (8).

Tab. 4-2 : Tabuľka nameraných hodnôt statického objektu kamerami Kinect v2 a SR300 (8)


Číslo merania [n]	Miesto merania	Fantóm (cm)	Fantóm Kinect v2 (cm)	Fantóm RealSense SR300 (cm)
1	1-2: Vlasý-koreň nosa	5,1	5,08	5,14
2	2 -3:Koreň nosa – špička nosa	3	3,10	3,31
3	3-4: Špička nosa–brada	6	5,95	6,24
4	5-6: Vnútorne kútiky očí	3,2	3,23	3,27
5	7-8: Vonkajšie kútiky očí	8,3	8,27	8,03
6	9-10: Pravé oko výška	1	1,03	0,85
7	7-5: Pravé oko šírka	2,4	2,43	2,32
8	11-12: Ľavé oko výška	0,8	0,76	0,69
9	6-8: Ľavé oko šírka	2	2,05	2,07
10	13-14: Šírka nosa	3,7	3,68	3,63
11	15-16: Kútiky úst	3,7	3,66	3,65
12	17-18: Spodok nosa–vrch pery	1,2	1,17	1,04
13	18-19: Výška pier	1,3	1,36	1,22
14	19-4: Spodná pera–brada	2,4	2,41	2,63
15	20-4: Ušnica – predok brada	10,5	10,47	10,34
16	21-22: Šírka krku	8,5	8,52	8,64

Meranie dynamických objektov, konkrétne pediatrických pacientov, bolo vykonané na Klinike detí a dorastu Jesseniovej lekárskej fakulty v Martine, Laboratórium spánkovej medicíny. Experimentálne bolo zmeraných 9 pacientov od veku 4 do 12 rokov (8). Pri snímaní


jednokamerovým systémom bola použitá kamera Kinect v2, pretože má priemerne nižšiu chybu merania, čo je vidieť v grafe 4-1. Počas merania objekty vykazovali pohyb, čo výrazne ovplyvnilo kvalitu výstupných modelov (obr 4-13). Pediatricí pacienti mali počas skenovania tendenciu otáčať hlavu za snímacím zariadením. Skenovanie pacienta trvalo vždy viac ako jednu minútu, počas ktorej pacient zvykol meniť výraz tváre (8).



Obr. 4-13 Ukážka modelu dynamického objektu



Graf 4-1 Absolútna chyba merania statického objektu kamerami Kinect v2 a SR300



Graf 4-2 Absolútna chyba merania dynamických objektov kamerou Kinect v2

Z grafu 4-2 vyplýva, že maximálna absolútna chyba merania pri 9 pacientoch bola 0,14 cm (graf 4-2). Z toho vyplýva, že RGB-D kamery môžu byť použité ako informatívne meradlo dynamických objektov. Avšak kvalita rekonštrukcie 3D modelu je nepostačujúca.

4.5 VIACKAMEROVÝ SYSTÉM

Použitím viackamerového systému vzniká možnosť rýchleho skenovania dynamických objektov. Rýchlym skenovaním je možné vytvoriť kvalitnejší 3D model, ktorý by realistickejšie znázorňoval pacienta. Táto podkapitola sa zameriava predovšetkým na prácu s kamerami Kinect v2, ktoré sú staticky rozložené v priestore. Spolupráca viacerých kamier je umožnená len s použitím knižnice Libfreenect2. Kinect SDK zatiaľ neumožňuje pripojenie viac ako jednej kamery. K spracovaniu prijatých dát sa používa knižnica PCL a OpenCV. Grafické prostredie je vytvárané v prostredí Qt.

4.5.1 Softvérové a hardvérové požiadavky

Pre pripojenie kamery Kinect v2 k PC je potrebné použiť adaptér. Kinect v2 požaduje USB 3.0 rozhranie, pretože šírka prenosového pásma USB 2.0 nie je postačujúca. Každá kamera potrebuje vlastnú rozširujúcu PCIe kartu. Odporúčané sú karty od značky Intel alebo NEC.


Pre zabezpečenie komunikácie kamier je použitý ovládač Libfreenect2, ktorý zabezpečuje prenos RGB, IR a hĺbkového obrazu a taktiež vykonáva registráciu RGB a hĺbkového obrazu. Jednou z funkcií je aj prenos registrovaných 2D dát do 3D mračna bodov (28). Tento ovládač pracuje na OS Windows 7 a vyššie, taktiež Mac OS X a Linuxových distribúciach s kernelom vyšším ako 3.16. Spracovanie hĺbky môže byť vykonávané cez OpenGL/OpenCL/CUDA.

K spracovaniu 2D dát prijatých z kamery je výhodné použiť knižnicu OpenCV, ktorá je určená k spracovaniu obrazu v real-time. Táto knižnica taktiež pracuje na všetkých bežných OS a na rôznych platformách ako je IOS alebo Android. Výhodou používania knižnice OpenCV je, že spracovanie 2D dát je výpočtovo menej náročné ako spracovanie 3D dát. Preto je výhodnejšie nevyužiť funkciu generovania 3D mračna bodov ovládača libfreenect2 a dáta najprv upravovať v 2D formáte. Z upravených obrazov je následne možné vytvoriť 3D dáta pomocou kalibračných koeficientov získaných z kalibrácie hĺbkovej mapy.

Knižnica Point Cloud Library (PCL) bola vytvorená k spracovaniu 3D dát získavaných z hĺbkových kamier. Ide o modernú C++ knižnicu, ktorá je navrhnutá na výkonnosť a efektívnosť v závislosti od moderných procesorov. Integruje v sebe filtrovanie, estimáciu vlastností dát (feature estimation), rekonštrukciu povrchov, registráciu mračien, segmentáciu, vizualizáciu a iné. PCL je ideálnym nástrojom pre prácu s viackamerovým systémom, pretože s mračnami bodov pracuje ako s objektmi. To umožňuje paralelizáciu jednotlivých výpočtových úkonov na dátach prijatých z kamier.

4.5.2 Vzájomná kalibrácia kamier

Z dôvodu ľahšej registrácie mračien bodov do jedného modelu sú kamery statické a vzájomne kalibrované. Statické umiestnenie kamier je zabezpečené pomocou pevnej konštrukcie, do ktorej stredu je možné umiestniť snímaný objekt. Technický návrh je znázornený na obrázku 4-14. Kalibrácia je následne vykonávaná pomocou multikalibrácie. Tou sa získavajú vonkajšie parametre kamier, ktorými sa nastavuje rotácia a translácia v spoločnom projektovanom priestore.




Obr. 4-14 Návrh konštrukcie skenovacej komory

Jedným zo spôsobov kalibrácie je vytvorenie obrazového stereo-páru z dvojice kamier, ktoré v rovnakom čase snímajú spoločný kalibračný objekt (obr. 4-15). Extrakciou spoločných kalibračných bodov a pomocou epipolárnej matematiky sú vypočítané rotačné a translačné parametre pre jednu kameru, pričom druhá kamera zostáva v pôvodnej polohe. Zobrazenie v spoločnom priestore získané nástrojom *Stereo Camera Calibration* nachádzajúceho sa v programe Matlab je na obr. 4-16.



Obr. 4-15 Kalibračný stereo-pár vytvorený staticky umiestnenými kamerami




Obr. 4-16 Vizualizácia rozloženia kamier v spoločnom priestore získaná stereo kalibráciou



Obr. 4-17 Vizualizácia rozloženia kamier v spoločnom priestore získaná stereo kalibráciou pri rôznych pohľadoch


4.5.3 Interferencia

Pri používaní viac-kamerového systému, kde každá kamera pracuje s rovnakou vlnovou dĺžkou vyžarovaného svetla, vzniká jav viackamerovej interferencie (obr. 4-18). Tento jav ovplyvňuje kvalitu výstupnej hĺbkovej mapy viac ako interferencia vzniknutá odrazom od prostredia (MPI). Signál je ergodický a širokospektrálny stacionárny stochastický proces (30).



Obr. 4-18 Meranie TOF metódou pri viac kamerovom systéme


Interferencia, ktorá vzniká v skenovacej komore (obr. 4-14) s použitými kamerami Kinect v2 je znázornená na obr. 4-19. V 3D rekonštruovanom modeli je vidieť artefakty, ktoré nereprezentujú skutočné geometrické rozloženie statického objektu (4-19a). Taktiež vznikajú miesta, ktoré vykazujú extrémne hodnoty vzdialenosti. Na obr. 4-19b sa nachádza hĺbková mapa, ktorá zachytáva statický objekt. Tento statický objekt je snímaný viac-kamerovým systémom, pričom vzniká interferencia ktorá je zvýraznená.



Obr. 4-19 a) 3D rekonštruovaný model s interferenciou, b) hĺbková mapa s interferenciou

4.5.4 Detekcia kľúčových bodov

K automatickej detekcii kľúčových bodov na tvári je možné použiť knižnicu DLib, ktorá je priamo určená k takýmto aplikáciám. Všetky algoritmy sú vysoko modulárne, rýchle a používajú sa pomocou moderného C++ API. Algoritmus Face Landmark Detection používaný k extrakcii bodov bol trénovaný na databáze LFW. Ten dokáže identifikovať 68 bodov, ktorých pozícia sa dá následne preniesť do 3D modelu. Zo špecifikovaných bodov sa pomocou triangulácie dá vypočítať euklidovská vzdialenosť (31).



Obr. 4-20 DLib-Facial Landmark Detection, 68 detegovaných bodov

5 NÁVRH TÉZ DIZERTAČNEJ PRÁCE

1. Návrh algoritmu umožňujúceho vytvorenie precízneho priestorového modelu objektu z viacerých kamier vrátane kalibrácie vizuálneho systému.
2. Algoritmus pre automatizovanú detekciu kľúčových bodov na objekte a automatizované meranie vybraných geometrických priestorových parametrov.

Riešenie úlohy definovanej v prvej téze je založené na paralelnom spracovávaní dát pomocou procesorových vlákien. Vláknamí je možné paralelne spúšťať jednotlivé procesy, čím sa dajú znížiť časové rozdiely medzi jednotlivými prijatými dátami z kamier. Tým pádom sa vytvorí skupina obrazov, ktoré budú vytvárať precíznejší 3D model dynamického objektu. K vytvoreniu realistického modelu budú taktiež odskúšané viaceré spôsoby kalibrácie, kde budú porovnané geometrické parametre rekonštruovaných modelov a reálnych objektov. V druhej téze možno k identifikácii kľúčových bodov tváre použiť knižnicu DLib. Tá dokáže v RGB-D obraze špecifikovať body, medzi ktorými sa v 3D priestore pomocou euklidovskej a triangulačnej matematiky vypočítajú euklidovské vzdialenosti.

ZÁVER

Táto práca sa zaoberá technickým riešením skríniového nástroja, určeného k pomocnej diagnostike syndrómu spánkového apnoe. V prvej časti je opísané medicínske pozadie spomínanej poruchy, kde je vysvetlený dôvod potreby vytvorenia podporného zariadenia umožňujúceho bezkontaktného merania pacientov.

V tretej kapitole je opísaný spôsob rekonštrukcie prostredia do 3D modelu. Bližšie vysvetlené boli technológie stereovízie, štrukturovaného svetla a merania doby letu. Taktiež boli opísané možnosti registrácie a rekonštrukcie dát, pomocou ktorých je možné dostať ucelený 3D model snímaného objektu.

Štvrtá kapitola obsahuje rozbor metód, ktoré sa zameriavajú na možnosti skenovania pacientov. Opísaná je kalibrácia štrbinového modelu kamery a multikalibrácie. Bližšie boli porovnávané dve kamery pracujúce na rozdielnych technologických princípoch. Kamera Microsoft Kinect v2 pracujúca TOF metódou a kamera Intel SR300 pracujúca metódou SLS. Z meraní sa zistilo, že kamera Kinect v2 dokáže vytvárať presnejšie 3D modely snímaných statických objektov. Pri snímaní dynamických objektov v jednokamerovom systéme sa zistilo, že RGB-D kamery dokážu postačujúco geometricky reprodukovať snímané objekty. Avšak výsledné 3D modely boli nekvalitné práve kvôli dĺžke snímania. Riešením je použitie viackamerového systému, ktorý skráti dobu skenovania, a tým aj vplyv pohybu objektu, na minimum. Spomenutý je aj vznik interferencie, ktorá výrazne ovplyvňuje kvalitu 3D rekonštrukcie modelov a možnosť automatizácie detekcie zaujímavých bodov tváre pomocou knižnice DLib.

Posledná kapitola obahuje ďalší postup pri vývoji skríniového nástroja, umožňujúceho zrýchlenie a objektivizáciu lekárskeho vyšetrenia. Viackamerový systém je postavený na paralizácii procesov a multikalibrácii.

BIBLIOGRAFIA

1. *International Classification of Sleep Disorders-Third Edition*. Sateia, Michael J. 2014, Chest Journal, pp. 1387-1394.
2. M., Muscka. Alpha Medical. *Syndróm spánkového apnoe*. [Online] 27. 7 2016. <https://www.alphamedical.sk/casopis-invitro/syndrom-spankoveho-apnoe>.
3. YOUNG, T. B., PEPPARD, P. Epidemiology of obstructive sleep apnoe. Breathing disorders in sleep. [aut. knihy] Neil A. Campbell Jane B. Reece. *Biology*. Toronto : Benjamin-Cummings Publishing Company, 2002, s. 31-43.
4. LAVIE P., PILLAR G., MALHOTRA A. *Poruchy spánku: Diagnostika, manažment a liečba*. Prvé vydanie. Trenčín : F, 2004. s. 171. 80-88952-158.
5. *Sleep clinical record: an aid to rapid and accurate diagnosis of paediatric sleep disordered breathing*. Villa, M. P.,... 2012, European Respiratory Journal, s. 1355-1361.
6. OpenCV. OpenCV. *Depth Map from Stereo Images*. [Online] 2014. https://docs.opencv.org/3.0-beta/doc/py_tutorials/py_calib3d/py_depthmap/py_depthmap.html.
7. *Structured-light 3D surface imaging: a tutorial*. Geng, J. 2011, Advances in Optics and Photonics, s. 128.
8. N., Sekel'ová. Využitie RGB-D snímačov v biomedicíne. Žilina : s.n., 2018.
9. *Three-dimensional imaging in the studio and elsewhere*. Gavriel J. Iddan, Gavriel J. Iddan, Giora Yahav, Giora Yahav. San Jose : s.n., 2001. Photonics West 2001 - Electronic Imaging.
10. Büttgen, B., Oggier, T., Lehmann, M., Kaufmann, R., & Lustenberger, F. *CCD / CMOS Lock-In Pixel for Range Imaging : Challenges , Limitations and State-of-the-Art*. 2005.
11. LI, L. *Time-of-flight camera-an introduction*. Technikal white paper. 2014.

-
12. HANSARD, M., LEE, S. a CHOI, O. *Time-of-flight cameras: principles, methods and applications*. s.l. : Springer Science & Business Media, 2012. 978-1-4471-4658-2.
 13. SHAO, L. et al. *Computer vision and machine learning with RGB-D sensors*. s.l. : Springer, 2014. 978-3-319-08650-7..
 14. Smith, Colin. *On Vertex-Vertex Systems and Their Use in Geometric and Biological Modelling*. THE UNIVERSITY OF CALGARY. Calgary : THE UNIVERSITY OF CALGARY, 2006.
 15. Baumart, Bruce G. *Winged edge polyherdon representation*. Stanford : Stanford University, 1972.
 16. Muller, D. E.; Preparata, F. P. *Finding the Intersection of Two Convex Polyhedra*. Illinois : UIUC, 1977. s. 217-236.
 17. *Primitives for the manipulation of general subdivisions and the computation of Voronoi diagrams*. Guibas L. J. , Stolfi J. 1985, ACM Transactions on Graphics, s. 75-123.
 18. Tsin Y., Kanade T. A Correlation-Based Approach to Robust Point Set Registration. [aut. knihy] Matas J. Pajdla T. *Computer Vision - ECCV 2004. ECCV 2004. Lecture Notes in Computer Science*. s.l. : Springer, Berlin, Heidelberg, 2004.
 19. GOLD, S. et al. *New algorithms for 2D and 3D point matching. In Pattern Recognition [online]*. 1998. s. 1019-1031.
 20. Intel Software. *Intel RealSense Camera SR300*. [Online] Intel. [Dátum: 15. 12 2018.] <https://software.intel.com/en-us/realsense/sr300>.
 21. team, OpenCV dev. OpenCV. *Camera Calibration and 3D Reconstruction*. [Online] OpenCV, 2019. https://docs.opencv.org/2.4/modules/calib3d/doc/camera_calibration_and_3d_reconstruction.html.
 22. MatWorks. MathWorks. *What Is Camera Calibration?* [Online] 2019. <https://www.mathworks.com/help/vision/ug/camera-calibration.html>.

-
23. HEIKKILA, J. - SILVEN, O. *San Juan, Puerto Rico : s.n., 1997. 1063-6919.*
 24. ZHANG, Z. *A flexible new technique for camera calibration. IEEE Transactions on Pattern Analysis and Machine Intelligence [online]. 2000, Zv. 22, 11, s. 1330-1334.*
 25. Hartley, R.I. *Theory and Practice of Projective Rectification. International Journal of Computer Vision. 35, 1999, 115.*
 26. Bouguet, Jean-Yves. *Camera Calibration Toolbox for Matlab. [Online] University of Caltech, 14. 10 2015. http://www.vision.caltech.edu/bouguetj/calib_doc/.*
 27. Tsuda, Atsushi. *Wiki Ros.org. Technical description of Kinect calibration. [Online] ROS.org, 2018. [Dátum: 7. 1 2019.] http://wiki.ros.org/kinect_calibration/technical.*
 28. ALI, L. et al. *The infuence of snoring, mouth breathing and apnoea on facial morphology in late childhood:a three dimensional study. BMJ Open. 2005, Zv. 5, 9.*
 29. LINGZHU XIANG et al. *Libfreenect2. [Online] 2016. <https://zenodo.org/record/50641>.*
 30. *Multi-camera interference cancellation of time-of-flight (TOF) cameras. Lianhua Li ; Sen Xiang ; You Yang ; Li Yu. Quebec : IEEE, 2015. 978-1-4799-8339-1.*
 31. *Dlib-ml: A Machine Learning Toolkit. Davis E, King. 2009, Journal of Machine Learning Research, s. 1755-1758.*

ZOZNAM PUBLIKÁCIÍ AUTORA

Konferencie

1. AFC - Michal Taraba (20%) - Jozef Volák (20%) - František Jablončík (20%) - Dušan Koniar (20%) - Libor Hargaš (20%) , Conditioning of Light Microscope for Advanced Methods of Ciliary Dyskinesia Diagnostics , Elektro 2018, Mikulov, Czech Republic, ISBN: 978-1-5386-4758-5
2. AFC - František Jablončík (20%) - Libor Hargaš (20%) - Dušan Koniar (20%) - Jozef Volák (20%) - Zuzana Loncová (20%), Dynamic objects detection of the respiratory epithelium based on image analysis , Elektro 2018, Mikulov, Czech Republic, ISBN: 978-1-5386-4758-5
3. AFC - Libor Hargaš (20%) - František Jablončík (20%) - Dušan Koniar (20%) - Jozef Volák (20%) - Zuzana Loncová (20%) , Identification of static objects in the respiratory epithelium, Elektro 2018 , Mikulov, Czech Republic, ISBN: 978-1-5386-4758-5
4. AFC - Jozef Volák (20%) - Dušan Koniar (20%) - Libor Hargaš (20%) - František Jablončík (20%) - Nikola Sekel'ová (5%) - Peter Ďurdík (15%) , RGB-D Imaging Used for OSAS Diagnostics, Elektro 2018 , Mikulov, Czech Republic, ISBN: 978-1-5386-4758-5
5. AFG- František Jablončík (25%) – Libor Hargaš (25%) – Dušan Koniar (25%) – Jozef Volák (25%), Contrast enhancement methods for images from the light microscope, IWBBIO 2018, Granada Spain, ISBN: 978-84-17293-36-9

6. AFC – Jozef Volák (100%), Stereovision in robotic systems, 22th International Student Conference on Electrical Engineering POSTER 2018, Prague, Czech Republic. ISBN: 978-80-01-06428-3

7. AFC - Jozef Volák (25%) - Dušan Koniar (25%) - František Jablončík (25%) - Libor Hargaš (25%) - A Study on OSAS Diagnostics Supported by RGB-D Imaging, 41st International Conference on Telecommunications and Signal Processing (TSP) 2018, Athens, Greece, ISBN: 978-1-5386-4695-3

8. AFD- František Jablončík - Jozef Volák - Libor Hargaš - Dušan Koniar - Peter Ďurdík - Júlia Kvaššayová - Peter Bánovčin: Návrh algoritmu pre automatickú segmentáciu statických cílií respiračného epitelu v obraze, XXXI. Slovensko-Poľské Vojtekove-Rudnikove dni detskej pneumológie a imunoalergológie, Nový Smokovec, Slovensko, prednáška (domáca konferencia)

9. AFD - Jozef Volák - Dušan Koniar - Libor Hargaš - František Jablončík - Peter Ďurdík – Dominika Šutvajová – František Duchoň – Peter Beňo: Technická podpora diagnostiky obštrukčného spánkového apnoe, XXXI. Slovensko-Poľské Vojtekove-Rudnikove dni detskej pneumológie a imunoalergológie, Nový Smokovec, Slovensko, prednáška (domáca konferencia)

Príspevky v odborných a impaktovaných časopisoch

10. ADM – Libor Hargaš (20%) – Zuzana Loncová (20%) – Dušan Koniar (20%) – František Jablončík (20%) – Jozef Volák (20%), Detection methods of static microscopic objects, Lecture Notes in Computer Sciences, ISSN: 0302-9743

11. ADC - Libor Hargaš - Dušan Koniar - František Jablončík - Jozef Volák - Peter Ďurdík - Peter Bánovčin: Automated Detection of Microscopic Dynamic Objects Using Computer Vision, Electrical Engineering, Springer, ISSN: 0948-7921 (Print) 1432-0487 (Online) [v revíznom konaní]